

统计 笔记

任云玮

目录

1	常见分布	2
1.1	离散分布	2
1.1.1	Hypergeometric Distribution	2
1.1.2	Binomial Distribution	2
1.1.3	Poisson Distribution	2
1.1.4	Negative Binomial Distribution	3
1.1.5	Geometric Distribution	4
1.2	连续分布	4
1.2.1	Exponential Distribution	4
1.2.2	Gamma Distribution	5
1.2.3	正态分布	5
2	Cheat Sheet	6
3	注解	7

1 常见分布

1.1 离散分布

1.1.1 Hypergeometric Distribution

含义 设有 N 个球，其中 M 个为红色， $N - M$ 个为绿色，它们除颜色以外无区别. 从中选取 K 个，考虑恰有 x 个是红球的概率分布.

公式

$$P(X = x|N, M, K) = \frac{\binom{M}{x} \binom{N-M}{K-x}}{\binom{N}{K}}.$$
$$E X = \frac{KM}{N}.$$
$$\text{Var } X = \frac{KM}{N} \frac{(N-M)(N-K)}{N(N-1)}.$$
$$x = 0, 1, \dots, K.$$

1.1.2 Binomial Distribution

含义 考虑 n 次相同的成功概率为 p 的 Bernoulli 试验，考虑其中恰有 y 次成功的概率分布.

公式

$$P(Y = y|n, p) = \binom{n}{y} p^y (1-p)^{n-y}.$$
$$E X = np$$
$$\text{Var } X = np(1-p).$$
$$M_X(t) = [pe^t + (1-p)]^n.$$

1.1.3 Poisson Distribution

含义 Poisson 分布可以用来描述在一段时间内，某事件发生的次数的概率分布，例如类似于等车的行为. 设 $t \geq 0$ 而 N_t 是关于 t 的整数值随机变量，设它满足如下性质：

1. 初始无到达： $N_0 = 0$ ；
2. 不相交时间区间内的达到次数相互独立： 设 $s < t$ ，则 N_s 和 $N_t - N_s$ 独立；
3. 到达次数近于区间长度有关： N_s 和 $N_{t+s} - N_t$ 是同分布的；
4. 当时间区间充分小时，到达可能性正比于区间长度： $\lim_{t \rightarrow 0} \frac{P(N_t = 1)}{t} = \lambda$ ；

5. 不会出现同时到达的情况: $\lim_{t \rightarrow 0} \frac{P(N_t > 1)}{t} = 0$;

经常的, 我们会进行归一化, 同时只考虑 $t = 1$ 的情况, 即“仅等一单位时间情况下, 等到车的数量”.

公式

$$P(N_t = n | \lambda) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}.$$

$$E N_1 = \lambda.$$

$$\text{Var } N_1 = \lambda.$$

$$M_{N_1}(t) = e^{\lambda(e^t - 1)}.$$

推导 我们仅考虑归一化的结果, 即一个单位时间的情况. 我们把该单位时间等分成足够多的 n , 则对于每一个小时时间段, 可以认为互相独立的 Bernoulli 试验, 其成功的概率是 λ/n . 则该单位时间的到达次数, 即为这 n 次 Bernoulli 试验的成功次数, 即为一个二项分布, 我们令 $n \rightarrow \infty$, 即得到 Poisson 分布的 pmf,

$$f(x) = \lim_{n \rightarrow \infty} \binom{n}{x} (\lambda/n)^x (1 - \lambda/n)^{1-x} = e^{-\lambda} \frac{\lambda^x}{x!}.$$

性质

1 定理 设 $X \sim \text{Poisson}(\theta)$, $Y \sim \text{Poisson}(\lambda)$ 且 X 和 Y 独立, 则 $X + Y \sim \text{Poisson}(\theta + \lambda)$.

利用 Poisson 分布近似 注意到 Poisson 描述的是连续的时间段中事件发生的情况, 在某些离散的情况下, 亦可以使用 Poisson 分布来近似. 考虑二项分布的情况, 我们可以把 Bernoulli 试验的成功理解成 Poisson 分布中的“到达”, 同时把单个的 Bernoulli 试验理解成一个单位时间, 则自然的 p 就对应着 λ . 若 p 充分小, 则可以认为这些离散的 Bernoulli 试验已经和连续的情况差不多, 所以此时可以有

$$P(Y = y | n, p) \sim P(N_n = y | p) = P(N_1 = y | np).$$

我们可以通过比较它们的递推式来证明这一结论.

1.1.4 Negative Binomial Distribution

含义 考虑 n 次独立的 Bernoulli(p) 试验, 设随机变量 X 表示在第 X 轮发生了等 r 次成功, 即描述一个成功了 r 次后才会停止的试验. 或者考虑一种等价的形式, 设随机变量 Y 表示在第 r 次成功前的失败的次数, 显然有 $Y = X - r$.

公式

$$\begin{aligned}P(X = x|r, p) &= \binom{x-1}{r-1} p^r (1-p)^{x-r} \\P(Y = y|r, p) &= \binom{r+y-1}{y} p^r (1-p)^y = (-1)^y \binom{-r}{y} p^r (1-p)^y. \\EY &= r \frac{1-p}{p}. \\Var Y &= r \frac{1-p^2}{p} = \mu + \frac{1}{2} \mu^2.\end{aligned}$$

利用负二项分布近似 Poisson 分布 注意到如果我们令 $p \rightarrow 1$ 而 $r \rightarrow \infty$ 且同时满足 $r(1-p) \rightarrow \lambda$, 则期望与方差都会趋于 λ , 和 Poisson 分布的结果一致. 这暗示了在这一条件下, 负二项分布或许可以近似 Poisson 分布, 而事实确实如此.

我们可以这样考虑这个事情. 当 r 变大时候, 一次试验在其中所占的份就变小了, 从而变得更加的连续了, 而在这里把一次失败理解成一次到达, 则 $p \rightarrow 1$ 的条件同 Poisson 分布中关于概率与区间长度的要求是一致的, 而 $r(1-p) \rightarrow \lambda$ 的要求可以从归一化之后的角度看待.

1.1.5 Geometric Distribution

含义 负二项分布中, 取 $r = 1$ 的特殊情况, 即一种成功就停止的试验.

公式

$$\begin{aligned}P(X = x|p) &= p(1-p)^{x-1}. \\EX &= \frac{1}{p}. \\Var X &= \frac{1-p}{p^2}.\end{aligned}$$

性质 之前的失败对于之后的概率没有影响, 即有

$$P(X > s|X > t) = P(X > s - t).$$

这也意味着如果某种概率是随着试验次数/时间的增长而有变化时, 几何分布是不适用的.

1.2 连续分布

1.2.1 Exponential Distribution

含义 已知在单位时间内事件发生的次数为 λ , W 为第一次事件发生前所经过的时间.

推导 我们下求 W 的 cdf 并求导以得其 pdf. 设 P_λ 为 Poisson 分布, 则

$$\begin{aligned} F(x) &= 1 - P(W > x) = 1 - P_\lambda(N_x = 0) = 1 - e^{-\lambda x} \\ \Rightarrow f(x) &= F'(x) = \lambda e^{-\lambda x}. \end{aligned}$$

公式 设 $\theta = 1/\lambda$ 表示所需等时间的期望, 则

$$\begin{aligned} f(x) &= \frac{1}{\theta} e^{-x/\theta}, \\ E(x) &= \theta, \\ \text{Var}(x) &= \theta^2, \\ x &\geq 0, \theta > 0. \end{aligned}$$

1.2.2 Gamma Distribution

含义 设单位时间内事件发生的次数为 λ , W 为第 α 次事件发生的时间. 记 $\theta = 1/\lambda$.

公式

$$\begin{aligned} f(x) &= \frac{1}{\Gamma(\alpha)\theta^\alpha} x^{\alpha-1} e^{-x/\theta}, \\ E(W) &= \alpha\theta \\ \text{Var}(W) &= \alpha\theta^2 \\ x &\geq 0, \alpha, \theta > 0. \end{aligned}$$

1.2.3 正态分布

公式 其参数即为其均值 μ 和方差 σ^2 .

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}, -\infty < x < \infty.$$

若 $X \sim n(\mu, \sigma^2)$, 则称 $Z = (X - \mu)/\sigma \sim n(0, 1)$ 呈 **标准正态分布**.

性质 正态分布的随机变量的 pdf 在 $x = \mu$ 处达到最大值, 在 $x = \mu \pm \sigma$ 处变换凹凸性.

利用正态分布近似二项分布 设 $X \sim \text{binomial}(n, p)$ 且 $Y \sim n(np, np(1-p))$, 则

$$P(X \leq x) \approx P(Y \leq x + 1/2), \quad P(X \geq x) \approx P(Y \geq x - 1/2).$$

其中 $\pm 1/2$ 为连续性修正.

2 Cheat Sheet

2 引理 (独立) 设 (X, Y) 为二元随机向量的 pmf 为 $f(x, y)$. 则随机变量 X 和 Y 独立当且仅当存在 $g(x)$ 和 $h(y)$ 使得对任意 $x, y \in \mathbb{R}$ 成立 $f(x, y) = g(x)h(y)$.

3 定理 (变换的 pdf) 设 $(U, V) = g(X, Y)$ 是从 $\mathcal{A} = \{(x, y) : f_{X,Y}(x, y) > 0\}$ 到 $\mathcal{B} = g(\mathcal{A})$ 的双射. 设 $h = g^{-1}$ 而 J 是 h 的 Jacob 行列式且 J 不恒为 0, 则

$$f_{U,V}(u, v) = f_{X,Y}(h(u, v))|J|.$$

TODO: p161

4 引理 (独立) 设 X 和 Y 为两个独立随机变量且 g 和 h 分别是仅关于 x 和 y 的函数, 则随机变量 $U = g(X)$ 和 $V = h(Y)$ 也独立.

5 引理 (协方差) $\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y)) = E XY - \mu_X \mu_Y$.

6 引理 设 X_1, \dots, X_n 是随机采样且 $g(x)$ 是一个满足 $E g(X_1)$ 和 $\text{Var } g(X_1)$ 存在的函数, 则有

$$\begin{aligned} E \left(\sum_{i=1}^n g(X_i) \right) &= n(E g(X_1)), \\ \text{Var} \left(\sum_{i=1}^n g(X_i) \right) &= n(\text{Var } g(X_1)). \end{aligned}$$

这一引理的 lhs 中的变换的形式 (求和), 是常见的统计的形式, 因此此引理可用于分析统计的均值和方差.

3 注解

p212 Definition 5.2.2/3 随机变量是指一个从样本空间 S 到 \mathbb{R} 的映射，而一个随机采样则是 n 个 iid 的随机变量。而一个统计是指一个从一个随机采样到 \mathbb{R}^n 的映射。而我们所定义的统计均值和统计方差都是一个统计，即是一个从映射（随机变量）到 \mathbb{R}^n 的映射。如果我们取定随机采样，则可以认为它是一个从样本空间到 \mathbb{R}^n 的映射，即它也是一个随机变量。从而我们可以讨论它的均值或者方差，讨论它的分布。这里要注意，统计均值/方差和均值/方差是完全不同的东西，前者（在取定随机采样后）是一个随机变量，而后者则是一个常数。

p214 Theorem 5.2.6 这里给出了之所以在定义统计方差时，分母用 $n-1$ 而非 n 。只有这样才可以使得 S^2 的期望恰好为 σ^2 ——各随机变量的各自的方差。

p232 Definition 5.5.1 首先再次注意随机变量是一个从样本空间到 \mathbb{R} 的映射，而 $P(|X_n - X| \geq \varepsilon)$ 表示这样一件事情：如果对于样本空间里的一个元素，如果 X_n 和 X 之间的差不小于 ε ，则把这个元素“对应”的概率加上，把所有这些元素都加上的结果即为 $P(|X_n - X| \geq \varepsilon)$ 。而此定义表明当 n 充分大的时候，这些概率累加的结果可以充分小。

p234 Definition 5.5.6 对于一个具体的式子，这一定义和 Definition 5.5.1 的一个区别在于，在后者中如果我们展开极限以外的部分，我们会得到一个关于 ε 和 n 的函数，需要这个函数在 $n \rightarrow \infty$ 时候趋于零（或者 1）。而在这一定义中，我们将不得不先处理极限，然后考察不满足要求的样本集合对应的概率。这一定义相较于 5.5.1 要更强，它表示函数“从概率角度”几乎处处点态收敛，而在 5.5.1 中，它实际上是一个数列的收敛性，可以理解为它是某个“概括”了 X_n 的数量的收敛性。

p235 Definition 5.5.10 即对应的 cdf 列在 F_X 的连续点集合上点态收敛。

p236 Theorem 5.5.13 “converges in distribution to μ ” 的直观含义就是结果一定是 μ 。